

Agent IA — Monitoring des Mentions

Documentation du projet de veille des réseaux sociaux

Ce document présente le projet de veille des mentions sur les réseaux sociaux. Il décrit le contexte, les défis rencontrés, les traitements effectués, la synchronisation avec Google Drive et l'intégration des agents IA Perplexity pour l'équipe dirigeante.

1. Contexte et objectif

Le projet permet de suivre l'activité digitale de comptes institutionnels ciblés sur **X (Twitter)** et **Facebook**. La plateforme **Mention** est utilisée pour configurer des alertes sur ces pages. Chaque semaine, les données sont **exportées manuellement au format Excel** depuis Mention par l'équipe. Ces fichiers peuvent contenir jusqu'à **50 000 lignes** selon la période.

Le projet couvre quatre périmètres : l'exécutif (tandem), les ministères, les ministres à titre personnel, et les représentations diplomatiques étrangères.

2. Le défi de la classification des publications

Le premier défi du projet a été de **distinguer les posts des commentaires** dans les données brutes. Les exports Mention ne contiennent pas de colonne indiquant le type d'une ligne. Il a donc fallu analyser les données pour trouver comment faire cette distinction.

Sur Facebook

Sur Facebook, la solution a été trouvée dans la colonne **source_name**. Quand une ligne provient d'un compte qui fait partie de la liste des pages surveillées, c'est un post. Sinon, c'est un commentaire laissé par un utilisateur externe.

Si source_name est dans la liste des comptes ciblés → **post**
Sinon → **commentaire**

Sur X (Twitter)

Sur X, la logique est différente car les commentaires et retweets apparaissent aussi avec le nom du compte cible dans source_name. La distinction a été trouvée dans le **contenu textuel** des publications :

- Un **retweet** commence par « RT »
- Un **commentaire** commence par « @ »
- Un **post original** ne correspond à aucun des deux cas

Ces règles simples, trouvées après exploration manuelle des fichiers, ont permis d'automatiser entièrement la classification sur les deux plateformes.

3. Traitements réalisés

Chargement et exploration des données

Le fichier Excel exporté depuis Mention est chargé et les premières lignes sont affichées pour vérifier la structure et les colonnes disponibles.

Classification posts / commentaires

Chaque ligne est classifiée selon les règles décrites ci-dessus. Sur Facebook, si le **source_name** appartient aux comptes ciblés c'est un post, sinon c'est un commentaire. Sur X, la classification se fait sur le contenu textuel (post, commentaire, retweet).

Filtrage des données

- Suppression des lignes provenant de sources non pertinentes
- Suppression des commentaires dont l'URL ne correspond à aucun post connu
- Suppression des colonnes techniques **id** et **alert_id**

Statistiques et visualisations

- Nombre de posts par source — diagramme en barres
- Nombre de commentaires par source — diagramme en barres horizontales
- Répartition posts vs commentaires — camembert
- Moyenne de posts par compte sur la période

Construction du DataFrame enrichi

Pour chaque post, le texte du post et l'ensemble des commentaires associés sont concaténés dans une seule colonne **texte**. Cela permet de passer d'un fichier de 50 000 lignes à quelques dizaines de lignes, chacune représentant un post avec tout son fil de commentaires.

Export Excel

Le fichier final est exporté au format Excel avec mise en forme : retour à la ligne dans les cellules, colonnes ajustées, et bloc de statistiques inséré dans la première ligne.

Fonctionnalités en cours de développement (non actives)

- Analyse de sentiments et extraction de mots-clés via API LLM + WordCloud
- Analyse temporelle : volume de posts par jour et par heure
- Calcul du taux de viralité (ratio commentaires / posts)
- Top 10 des posts par portée directe (direct_reach)

4. Structure du fichier de sortie

Le fichier Excel généré contient une ligne par post avec les colonnes suivantes :

- **url** : lien vers le post original
- **count** : nombre de commentaires reçus
- **source_name** : nom du compte qui a publié
- **texte** : texte du post + tous les commentaires, séparés par des sauts de ligne
- **published_at** : date et heure de publication
- **statistiques** : bloc récapitulatif présent uniquement sur la première ligne

Exemple : Un post ayant reçu 2 786 commentaires occupe une seule ligne. La cellule « texte » contient le post suivi de tous les commentaires. La cellule « statistiques » de la première ligne indique le nombre total de posts et commentaires par compte sur la période.

5. Synchronisation automatique sur Google Drive

Une fois le fichier Excel de sortie généré, il est automatiquement uploadé sur **Google Drive** dans un dossier dédié à chaque périmètre. Avant chaque upload, le dossier est vidé pour que Drive contienne toujours uniquement la version la plus récente.

L'authentification avec Google Drive est gérée via OAuth2. Le token est sauvegardé après la première connexion, ce qui permet aux exécutions suivantes de se connecter automatiquement.

Chaque périmètre dispose de son propre dossier Drive, ce qui permet à chaque équipe d'accéder uniquement aux données qui la concernent.

6. Agents IA Perplexity

Google Drive est connecté à **Perplexity**. Des agents IA ont été créés pour l'équipe de production, chacun associé à un périmètre de surveillance. Chaque agent dispose d'un **prompt** qui lui décrit précisément la structure du fichier Excel de sortie : à quoi correspond chaque colonne, où trouver les statistiques, et comment interpréter le regroupement post-commentaires.

Grâce à cette configuration, l'équipe dirigeante peut interroger les données en langage naturel directement dans Perplexity, sans ouvrir le fichier Excel et sans manipulation technique. L'agent lit le fichier Drive et fournit une réponse synthétique en quelques secondes.

L'ensemble du pipeline — export manuel depuis Mention, traitement automatisé, upload Drive, lecture par l'agent IA — permet à l'équipe dirigeante d'avoir une synthèse de l'activité des réseaux sociaux chaque semaine en quelques clics.

7. Interface utilisateur

Une interface web développée avec **Streamlit** permet à l'équipe de production d'utiliser le système sans manipulation de code. Elle propose quatre sections correspondant aux quatre périmètres. L'opérateur dépose le fichier brut exporté depuis Mention, lance le traitement, et télécharge le fichier Excel de sortie.

8. Technologies utilisées

- **Python 3** — langage principal
- **pandas** — manipulation et agrégation des données
- **xlsxwriter** — export Excel avec mise en forme
- **matplotlib** — visualisations statistiques
- **Streamlit** — interface web
- **PyDrive2** — authentification et synchronisation Google Drive
- **Mention** — plateforme de veille, export manuel Excel
- **Google Drive** — stockage et partage des fichiers de sortie
- **Perplexity** — agents IA pour l'analyse des données